

HW2

asandstar@github

2022 年 10 月 26 日

- 1 现有下表所示训练数据，给定感知机模型 $z = \text{sgn}(w_1x + w_2y + b)$
参数取值为 $w_1 = 1, w_2 = 1, b = -1$
步长 $\eta = 0.5$ ，试学习感知机权重，给出过程

x	y	z
-0.89	-1.62	-1
-0.30	0.96	+1
1.49	0.25	+1
0.06	-0.68	-1
-1.13	0.14	-1
0.78	0.96	+1

设 $\mathbf{w} = (w_1, w_2, b)$, $\mathbf{X}^\top = (x, y, 1)$, 模型 $z = \text{sgn}(\mathbf{w} \cdot \mathbf{X})$

其中已知 $w_1 = 1, w_2 = 1, b = -1$, 所以 $z = \text{sgn}(x + y - 1)$

选择一个数据点 (x_i, y_i, z_i) , 如果分类错误则更新参数 $\mathbf{w} \leftarrow \mathbf{w} + \eta \mathbf{X}_i z_i$,

(1) 对 $\mathbf{X}_1^\top = (-0.89, -1.62, -1)$, $\mathbf{w} = (1, 1, -1)$,

代入得 $z = \text{sgn}(-0.89 + (-1.62) - 1) = -1$, 分类正确

(2) 对 $\mathbf{X}_2^\top = (-0.30, 0.96, +1)$, $\mathbf{w} = (1, 1, -1)$,

代入得 $z = \text{sgn}(-0.30 + 0.96 - 1) = -1 \neq +1$, 分类错误

更新参数 $\mathbf{w} = (1, 1, -1) + 0.5 \times (-0.30, 0.96, 1) \times (+1) = (0.85, 1.48, -0.5)$

(3) 对 $\mathbf{X}_1^\top = (-0.89, -1.62, -1)$, $\mathbf{w} = (0.85, 1.48, -0.5)$,

代入得 $z = \text{sgn}(0.85 \times (-0.89) + 1.48 \times (-1.62) - 0.5) = -1$, 分类正确

(4) 对 $\mathbf{X}_2^\top = (-0.30, 0.96, +1)$, $\mathbf{w} = (0.85, 1.48, -0.5)$,

代入得 $z = \text{sgn}(0.85 \times (-0.30) + 1.48 \times 0.96 - 0.5) = +1$, 分类正确

(5) 对 $\mathbf{X}_3^\top = (1.49, 0.25, +1)$, $\mathbf{w} = (0.85, 1.48, -0.5)$,

代入得 $z = \text{sgn}(0.85 \times 1.49 + 1.48 \times 0.25 - 0.5) = +1$, 分类正确

(6) 对 $\mathbf{X}_4^\top = (0.06, -0.68, -1)$, $\mathbf{w} = (0.85, 1.48, -0.5)$,

代入得 $z = \text{sgn}(0.85 \times 0.06 + 1.48 \times (-0.68) - 0.5) = -1$, 分类正确

(7) 对 $\mathbf{X}_5^\top = (-1.13, 0.14, -1)$, $\mathbf{w} = (0.85, 1.48, -0.5)$,

代入得 $z = \text{sgn}(0.85 \times (-1.13) + 1.48 \times 0.14 - 0.5) = -1$, 分类正确

(8) 对 $\mathbf{X}_6^\top = (0.78, 0.96, +1)$, $\mathbf{w} = (0.85, 1.48, -0.5)$,

代入得 $z = \text{sgn}(0.85 \times 0.78 + 1.48 \times 0.96 - 0.5) = +1$, 分类正确

综上, 感知机权重为 $\mathbf{w} = (w_1, w_2, b) = (0.85, 1.48, -0.5)$

2 现有以下数据

$$x = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 0 \\ 2.5 & 2 & 0 \\ -2 & -2 & 1 \\ -2.7 & -1 & 1 \\ -3 & -2.2 & 1 \end{bmatrix}$$

其中每行为一个样本, 前 2 列为属性, 第 3 列表示类别, 试应用 LDA 算法计算投影后的数据点

LDA 的思想: 给定训练样例集, 设法将样例投影到一条直线上, 使得同类样例的投影点尽可能接近、异类样例的投影点尽可能远离; 在对新样本进行分类时, 将其投影到同样的这条直线上, 再根据投影点的位置来确定新样本的类别。

设 μ_i 为第 i 类的均值向量, 例如 $\mu_0 = (\mathbf{x}_0, \mathbf{y}_0)^\top$ 为类别 0 的样本中心点

$$\mathbf{w}^\top = (w_0, w_1)$$

$\mathbf{w}^\top \mu_0, \mathbf{w}^\top \mu_1$ 为两类样本的中心在直线上的投影

$\mathbf{w}^\top \Sigma_0 \mathbf{w}, \mathbf{w}^\top \Sigma_1 \mathbf{w}$ 为投影所有的点到直线后, 两类样本的协方差

(1) 使同类样例的投影点尽可能接近, 可以让同类样例投影点的协方差尽可能小, 即 $\mathbf{w}^\top \Sigma_0 \mathbf{w} + \mathbf{w}^\top \Sigma_1 \mathbf{w}$ 尽可能小

(2) 使异类样例的投影点尽可能远离, 可以让类中心之间的距离尽可能大, 即 $\|\mathbf{w}^\top \mu_0 - \mathbf{w}^\top \mu_1\|_2^2$

$$\text{所以最大化的目标为 } J = \frac{\|\mathbf{w}^\top \mu_0 - \mathbf{w}^\top \mu_1\|_2^2}{\mathbf{w}^\top \Sigma_0 \mathbf{w} + \mathbf{w}^\top \Sigma_1 \mathbf{w}} = \frac{\mathbf{w}^\top (\mu_0 - \mu_1)(\mu_0 - \mu_1)^\top \mathbf{w}}{\mathbf{w}^\top (\Sigma_0 + \Sigma_1) \mathbf{w}}$$

定义类内散度矩阵 $\mathbf{S}_w = \Sigma_0 + \Sigma_1$

$$= \sum_{x \in X_0} (\mathbf{x} - \mu_0)(\mathbf{x} - \mu_0)^\top + \sum_{x \in X_1} (\mathbf{x} - \mu_1)(\mathbf{x} - \mu_1)^\top$$

定义类间散度矩阵 $\mathbf{S}_b = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^\top$

$$\text{则最大化的目标可化为 } S_w \text{ 和 } S_b \text{ 的广义瑞利商 } J = \frac{\mathbf{w}^\top \mathbf{S}_b \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_w \mathbf{w}}$$

注意到上式的分子和分母都是关于 \mathbf{w} 的二次项, 因此上式的解与 \mathbf{w} 的长度无关, 只与其方向有关, 所以令 $\mathbf{w}^\top \mathbf{S}_w \mathbf{w} = 1$

故最大化的目标等价于

$$\begin{aligned} \min_w & -\mathbf{w}^\top \mathbf{S}_b \mathbf{w} \\ \text{s.t.} & \mathbf{w}^\top \mathbf{S}_w \mathbf{w} = 1 \end{aligned}$$

利用拉格朗日乘子法得 (λ 为拉格朗日乘子)

$$L(w, \lambda) = -\mathbf{w}^\top \mathbf{S}_b \mathbf{w} + \lambda(\mathbf{w}^\top \mathbf{S}_w \mathbf{w} - 1)$$

对上式求导并令其为 0 得

$$\frac{\partial L}{\partial \mathbf{w}} = -2\mathbf{S}_b \mathbf{w} + 2\lambda \mathbf{S}_w \mathbf{w} = 0$$

因为 $\mathbf{w}^\top \mu$ 为标量, 所以 $\mathbf{S}_b \mathbf{w} = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^\top \mathbf{w}$ 中的 $(\mu_0 - \mu_1)^\top \mathbf{w}$ 也为标量, 即 $\mathbf{S}_b \mathbf{w}$ 的方向仅与 $(\mu_0 - \mu_1)$ 有关

不妨令 $\mathbf{S}_b \mathbf{w} = \lambda(\mu_0 - \mu_1)$, 代入上述求导所得等式得

$$\mathbf{w} = \mathbf{S}_w^{-1}(\mu_0 - \mu_1)$$

对 \mathbf{S}_w 进行奇异值分解 $\mathbf{S}_w = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$, 其中 $\mathbf{\Sigma}$ 为实对角矩阵, 其对角线上的元素是 \mathbf{S}_w 的奇异值
再求逆得 $\mathbf{S}_w^{-1} = \mathbf{V}\mathbf{\Sigma}^{-1}\mathbf{U}^\top$, 并求得 w

由题可知被投影的直线 l_1 斜率 $k = \frac{w_0}{w_1}$

所以与该直线垂直的直线 l_2 斜率 $k' = -\frac{w_1}{w_0}$

l_2 代入数据点, 再与 l_1 联立即可求得投影点

具体公式为 $x' = \frac{x + y \cdot k'}{(k')^2 + 1}, y' = kx'$

利用 python 求解的代码如下

```

1  from statistics import mean
2  import numpy as np
3  import matplotlib.pyplot as plt
4  '''1. 导入数据'''
5  xy = np.array([[1, 2], [3, 1], [2.5, 2], [-2, -2], [-2.7, -1], [-3, 1]])
6  xy0 = np.array(xy[:3]) #3*2维
7  xy_0 = np.array(xy[:3])
8  xy1 = np.array(xy[3:]) #3*2维
9  xy_1 = np.array(xy[3:])
10 #数据按题干x摆放, 第一列是x, 第二列是y
11 '''2. 计算miu0, miu1'''
12 x0 = mean(xy0[:, 0])
13 y0 = mean(xy0[:, 1])
14 x1 = mean(xy1[:, 0])

```

```

15 y1 = mean(xy1[:, 1])
16 miu0 = [x0, y0]
17 miu1 = [x1, y1]
18 '''3.计算类内散度矩阵Sw'''
19 for i in range(3):
20     xy0[i][0] = xy0[i][0] - x0
21     xy0[i][1] = xy0[i][1] - y0
22     xy1[i][0] = xy1[i][0] - x1
23     xy1[i][1] = xy1[i][1] - y1
24     #xy0从x中类别为0的矩阵变为x- 的矩阵
25 sig0 = sig1 = 0
26 for i in range(3):
27     sig0 = sig0 + np.outer(xy0[i], xy0[i].T)
28     sig1 = sig1 + np.outer(xy1[i], xy1[i].T)
29     #某类中每一个i的(x-miu)与(x-miu)^T先外积, 再对i求和
30 sw = sig0 + sig1 #2×2维
31 '''4.Sb·w的方向'''
32 miu01 = np.array([x0 - x1, y0 - y1]) #miu0-miu1
33 '''5.得到w'''
34 swni = np.linalg.inv(sw) #求逆
35 w = np.dot(swni, miu01)
36 '''6.投影点公式'''
37 k = w[0] / w[1]
38 kt = -w[1] / w[0]
39 xty = (xy[:, 0] + xy[:, 1] * k) / (k**2 + 1)
40 yty = k * xty
41 xyty = np.array([xty, yty])
42 xyty = xyty.T
43 print('投影后数据点: \n', xyty)
44 '''7.画图'''
45 #画出题千数据点、被投影的直线
46 plt.scatter(xy_0[:, 0], xy_0[:, 1], c='b', label='+', marker='+')
47 plt.scatter(xy_1[:, 0], xy_1[:, 1], c='r', label='-', marker='_')
48 plt.plot([-3.5, 3.5], [-3.5 * k, 3.5 * k], label='y')
49 #画出投影点与原数据点的连线
50 for i in range(6):
51     plt.plot([xy[i][0], xyty[i][0]], [xy[i][1], xyty[i][1]])
52 plt.xlabel('X1', fontproperties='SimHei', fontsize=15, color='black')
53 plt.ylabel('X2', fontproperties='SimHei', fontsize=15, color='black')

```

```

54 plt.xlim(-4, 4)
55 plt.ylim(-4, 4)
56 ax = plt.gca()
57 ax.set_aspect(1)
58 plt.legend()
59 plt.show()

```

求得结果为 $w = [3.30924855, 1.84393064]^T$


投影后数据点：

```

[[ 1.08730441  1.95135353]
 [ 1.13595088  2.03865794]
 [ 1.44268362  2.58914223]
 [-1.32422388 -2.37654599]
 [-1.06487504 -1.91110019]
 [-0.28556595 -0.51249688]]

```

python 作图如下



3 现用梯度下降求解优化问题：

$$x^* = \arg \min_x f(x)$$

即迭代公式为

$$x_{i+1} = x_i - \eta \frac{\partial f}{\partial x}$$

若 f 是二阶多项式, 试证明迭代收敛的条件是 $\eta < 2 \left(\frac{\partial^2 f}{\partial x^2} \right)^{-1}$

设 f 的表达式为 $f(x) = ax^2 + bx + c$, 则 $\frac{\partial f}{\partial x} = 2ax + b$, $\frac{\partial^2 f}{\partial x^2} = 2a$

又 $f(x)$ 有最小值, 故 $a > 0$

$$\begin{aligned} \text{因为 } \left\| \frac{\partial f}{\partial x} - \frac{\partial f}{\partial y} \right\| &= \left\| \|2ax + b\| - \|2ay + b\| \right\| \\ &\leq \|2a(x - y)\| \\ &\leq 2a\|x - y\| \end{aligned}$$

即存在 $L = 2a$, 使 $\|f'(x) - f'(y)\| \leq L\|x - y\|$

所以 f' 满足 Lipschitz continuous 条件, f 符合 Lipschitz continuous gradient

由 Descent Lemma, $f(x) \leq f(y) + \frac{\partial f}{\partial x}(x - y) + \frac{L}{2}\|x - y\|^2$

在上式中把 x, y 换成 x_{i+1}, x_i 得 $f(x_{i+1}) \leq f(x_i) + \frac{\partial f}{\partial x}(x_{i+1} - x_i) + \frac{L}{2}\|x_{i+1} - x_i\|^2$

又因为 $x_{i+1} - x_i = -\eta \frac{\partial f}{\partial x}$,

代入上述 Descent Lemma 得到的不等式得

$$\begin{aligned} f(x_{i+1}) &\leq f(x_i) - \eta\|f'(x_i)\|^2 + \frac{L}{2}\|\eta f'(x_i)\|^2 \\ &= f(x_i) - (\eta - \frac{L}{2}\eta^2)\|f'(x_i)\|^2 \end{aligned}$$

要使迭代收敛, 需要满足 $\eta - \frac{L}{2}\eta^2 > 0$, 解得 $\eta < \frac{2}{L}$

而 $L = 2a = \frac{\partial^2 f}{\partial x^2}$

所以迭代的收敛条件为 $\eta < 2 \left(\frac{\partial^2 f}{\partial x^2} \right)^{-1}$

证毕

4 简答: 使用 OvR 和 MvM 将多分类任务分解为二分类任务求解时, 试概述针对类别不平衡性处理的方法。

类别不平衡学习的基本策略是 rescaling(再缩放)。

以线性分类器为例, 用 $y = \mathbf{w}^\top \mathbf{x} + b$ 对 \mathbf{w}^\top 进行分类时, 是用预测的 y 和某个阈值相比较, 实际上 y 是 \mathbf{x} 属于某类(正例或反例)的可能性

$\frac{y}{1-y}$ 指正例可能性和反例可能性的比值

阈值 = 0.5 表明分类器认为真实正、反例可能性相同

分类器决策规则： $\frac{y}{1-y} > 1$ 时，预测为正例

训练集中正、反例数目不同时，令 m^+ 为正例数， m^- 为反例数，故观测几率可以表示为 $\frac{m^+}{m^-}$

假设训练集是真实样本总体的无偏采样，则观测几率代表真实几率

一旦分类器的预测几率高于观测几率，判定为正例，即 $\frac{y}{1-y} > \frac{m^+}{m^-}$ 时，预测为正例

但 $\frac{y}{1-y} > 1$ 是分类器使用的决策依据，所以对预测值进行调整，令

$$\frac{y'}{1-y'} = \frac{y}{1-y} \times \frac{m^+}{m^-}$$

实际情况是，因为“训练集是真实样本总体的无偏采样”的假设往往不成立，不能用观测几率代表真实几率，现在主要有三类做法。

(1) “欠采样” (undersampling)

去除训练集里的反类样例中一些反例使得正、反例数目接近，再学习

(2) “过采样” (oversampling)

增加训练集里的正类样例中一些正例使得正、反例数目接近，再学习

(3) “阈值移动” (threshold-moving)

基于原始训练集进行学习，并在用训练好的分类器进行预测时，把式子 $\frac{y'}{1-y'} = \frac{y}{1-y} \times \frac{m^+}{m^-}$ 嵌入到其决策过程中

5 请写出求解支撑矢量机优化问题的 SMO 算法流程，其中在固定 λ_{i1} 和 λ_{i2} 以外的参数时，推导下面原优化问题的闭式解 λ_{i1}^* 和 λ_{i2}^*

$$\max_{\lambda_i \geq 0} \left\{ \sum_i \lambda_i - \frac{1}{2} \left(\sum_i \sum_j \lambda_i \lambda_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) \right) \right\}$$

$$s.t. \sum_i \lambda_i y_i = 0$$

因为存在约束 $\sum_i \lambda_i y_i = 0$ ，如果固定 $\lambda_{i1}, \lambda_{i2}$ 之外其他变量，则 $\lambda_{i1}, \lambda_{i2}$ 可由其他变量导出

$$\begin{aligned} \lambda_{i1} y_1 + \lambda_{i2} y_2 &= -\sum_{i \neq 1,2} \lambda_i y_i = \varsigma \\ 0 &\leq \lambda_i \leq C, i = 1, 2 \end{aligned}$$


故题干最优化子问题，省略不含 $\lambda_{i1}, \lambda_{i2}$ 的常数项后，可写成：

$$\begin{aligned} \min_{\lambda_{i1}, \lambda_{i2}} W(\lambda_{i1}, \lambda_{i2}) &= \frac{1}{2} (\mathbf{x}_1 \cdot \mathbf{x}_1) \lambda_{i1}^2 + \frac{1}{2} (\mathbf{x}_2 \cdot \mathbf{x}_2) \lambda_{i2}^2 + y_1 y_2 (\mathbf{x}_1 \cdot \mathbf{x}_2) \lambda_{i1} \lambda_{i2} \\ &\quad - (\lambda_{i1} + \lambda_{i2}) + y_1 \lambda_{i1} \sum_{i \neq 1,2} y_i \lambda_i (\mathbf{x}_i \cdot \mathbf{x}_1) + y_2 \lambda_{i2} \sum_{i \neq 1,2} y_i \lambda_i (\mathbf{x}_i \cdot \mathbf{x}_2) \end{aligned}$$

$$s.t. \quad \lambda_{i1} y_1 + \lambda_{i2} y_2 = \varsigma$$

$$0 \leq \lambda_i \leq C, i = 1, 2$$

求解上述两个变量的二次规划问题，先要分析约束条件，然后在约束条件下求极小
只有两个变量，约束可以用二维空间中的图形表示



因为不等式约束 $0 \leq \lambda_i \leq C, i = 1, 2$ 使 $(\lambda_{i1}, \lambda_{i2})$ 在 $[0, C] \times [0, C]$ 内
且等式约束 $\lambda_{i1}y_1 + \lambda_{i2}y_2 = \varsigma$ 使 $(\lambda_{i1}, \lambda_{i2})$ 在平行于 $[0, C] \times [0, C]$ 的对角线的直线上
所以要求是目标函数在一条平行于对角线的线段上的最优值

又因为 $\lambda_{i1}y_1 + \lambda_{i2}y_2 = \varsigma$ ，其中 ς 为常数，所以上述两个变量的最优化问题实质上是单变量的最优化问题，不妨设该问题是 λ_{i2} 的最优化问题

设问题的初始可行解为 $\lambda_{i1}, \lambda_{i2}$ ，最优解 $\lambda_{i1}^*, \lambda_{i2}^*$ ，设在沿着约束方向未考虑不等式 $0 \leq \lambda_i \leq C, i = 1, 2$ 约束时 λ_{i2} 的最优解是 $\lambda_{i2}^{*,unc}$

由图可以看出， $L \leq \lambda_{i2}^* \leq H$ ，其中 L, H 是 λ_{i2}^* 所在的平行于对角线的线段端点的界

$$(1) y_1 \neq y_2, \text{ 则 } L = \max(0, \lambda_{i2} - \lambda_{i1}), H = \min(C, C + \lambda_{i2} - \lambda_{i1})$$

$$(2) y_1 \neq y_2, \text{ 则 } L = \max(0, \lambda_{i2} + \lambda_{i1} - C), H = \min(C, \lambda_{i2} + \lambda_{i1})$$

接着，先求沿约束方向未考虑不等式 $0 \leq \lambda_i \leq C, i = 1, 2$ 约束时 λ_{i2} 的最优解 $\lambda_{i2}^{*,unc}$
再求考虑不等式 $0 \leq \lambda_i \leq C, i = 1, 2$ 约束后的解 λ_{i2}^*

$$\text{令 } g(x) = \sum_{i=1} \lambda_i y_i (\mathbf{x}_i \cdot \mathbf{x}) + b$$

$$E_i = g(x_i) - y_i = \left(\sum_{i=1} \lambda_i y_i (\mathbf{x}_i \cdot \mathbf{x}) + b \right) - y_i, i = 1, 2$$

$$v_i = \sum_{j \neq 1, 2} y_j \lambda_j (\mathbf{x}_i \cdot \mathbf{x}_j) = g(x_i) - \sum_{j=1}^2 \lambda_j y_j (\mathbf{x}_i \cdot \mathbf{x}_j) - b, i = 1, 2$$

目标函数可写成

$$W(\lambda_{i1}, \lambda_{i2}) = \frac{1}{2}(\mathbf{x}_1 \cdot \mathbf{x}_1)\lambda_{i1}^2 + \frac{1}{2}(\mathbf{x}_2 \cdot \mathbf{x}_2)\lambda_{i2}^2 + y_1 y_2 (\mathbf{x}_1 \cdot \mathbf{x}_2) \lambda_{i1} \lambda_{i2} \\ - (\lambda_{i1} + \lambda_{i2}) + y_1 \lambda_{i1} v_1 + y_2 \lambda_{i2} v_2$$

由 $\lambda_{i1} y_1 = \varsigma - \lambda_{i2} y_2, y_i^2 = 1$, 故 $\lambda_{i1} = (\varsigma - \lambda_{i2} y_2) y_1$

代入 $W(\lambda_{i1}, \lambda_{i2})$ 得

$$W(\lambda_{i2}) = \frac{1}{2}(\mathbf{x}_1 \cdot \mathbf{x}_1)(\varsigma - \lambda_{i2} y_2)^2 + \frac{1}{2}(\mathbf{x}_2 \cdot \mathbf{x}_2)\lambda_{i2}^2 + y_2(\mathbf{x}_1 \cdot \mathbf{x}_2)(\varsigma - \lambda_{i2} y_2)\lambda_{i2} \\ - (\varsigma - \lambda_{i2} y_2) y_1 - \lambda_{i2} + (\varsigma - \lambda_{i2} y_2) v_1 + y_2 \lambda_{i2} v_2$$

对 λ_{i2} 求导并令其等于零

$$\frac{\partial W}{\partial \lambda_{i2}} = (\mathbf{x}_1 \cdot \mathbf{x}_1)\lambda_{i2} + (\mathbf{x}_2 \cdot \mathbf{x}_2)\lambda_{i2} - 2(\mathbf{x}_1 \cdot \mathbf{x}_2)\lambda_{i2} - (\mathbf{x}_1 \cdot \mathbf{x}_1)\varsigma\lambda_{i2} \\ + (\mathbf{x}_1 \cdot \mathbf{x}_2)\varsigma\lambda_{i2} + y_1 y_2 - 1 - y_2 v_1 + y_2 v_2 = 0$$

$$((\mathbf{x}_1 \cdot \mathbf{x}_1) + (\mathbf{x}_2 \cdot \mathbf{x}_2) - 2(\mathbf{x}_1 \cdot \mathbf{x}_2))\lambda_{i2} \\ = y_2(y_2 - y_1 + \varsigma(\mathbf{x}_1 \cdot \mathbf{x}_1) - \varsigma(\mathbf{x}_1 \cdot \mathbf{x}_2) + v_1 - v_2)$$

$$= y_2 \left[y_2 - y_1 + \varsigma(\mathbf{x}_1 \cdot \mathbf{x}_1) - \varsigma(\mathbf{x}_1 \cdot \mathbf{x}_2) + \left(g(x_1) - \sum_{j=1}^2 \lambda_j y_j (\mathbf{x}_1 \cdot \mathbf{x}_j) - b \right) \right. \\ \left. - \left(g(x_2) - \sum_{j=1}^2 \lambda_j y_j (\mathbf{x}_2 \cdot \mathbf{x}_j) - b \right) \right]$$

$$\text{代入 } \varsigma = \lambda_{i1} y_1 + \lambda_{i2} y_2 \text{ 得 } ((\mathbf{x}_1 \cdot \mathbf{x}_1) + (\mathbf{x}_2 \cdot \mathbf{x}_2) - 2(\mathbf{x}_1 \cdot \mathbf{x}_2))\lambda_{i2}^{*,unc} \\ = y_2(((\mathbf{x}_1 \cdot \mathbf{x}_1) + (\mathbf{x}_2 \cdot \mathbf{x}_2) - 2(\mathbf{x}_1 \cdot \mathbf{x}_2))\lambda_{i2} y_2 + y_2 - y_1 + g(x_1) + g(x_2)) \\ = ((\mathbf{x}_1 \cdot \mathbf{x}_1) + (\mathbf{x}_2 \cdot \mathbf{x}_2) - 2(\mathbf{x}_1 \cdot \mathbf{x}_2))\lambda_{i2} + y_2(E_1 - E_2)$$

令 $\eta = ((\mathbf{x}_1 \cdot \mathbf{x}_1) + (\mathbf{x}_2 \cdot \mathbf{x}_2) - 2(\mathbf{x}_1 \cdot \mathbf{x}_2))$ 得到

$$\lambda_{i2}^{*,unc} = \lambda_{i2} + \frac{y_2(E_1 - E_2)}{\eta}$$

为满足不等式约束条件, 将上式限制在 $[L, H]$ 间, 可得 λ_{i2}^* 表达式

$$\lambda_{i2}^* = \begin{cases} H, & \lambda_{i2}^{*,unc} > H \\ \lambda_{i2}^{*,unc}, & L \leq \lambda_{i2}^{*,unc} \leq H \\ L, & \lambda_{i2}^{*,unc} < L \end{cases}$$

$$\lambda_{i1}^* = \lambda_{i1} + y_1 y_2 (\lambda_{i2} - \lambda_{i2}^*)$$